

司玉栋

☐ 19121726080 ☐ 1505632943@qq.com ☐ <https://github.com/yudongsi>

☐ 教育经历


同济大学 - 硕士 - 集成电路工程专业

2019.09 - 2022.03

☐ 工作经验

AI框架工程师 (Triton编译器) @英特尔亚太研发有限公司

2022.07 - 2025.07



Triton 编译器 XPU 后端开发

• 后端开发

- 增加后端launcher对Global Scratch Memory的支持
- 构建AOT编译工具链(SPIRV->LevelZero->SYCL) , 方便底层问题的复现
- 开发Intel专用Pass: tritonintelgpu-rewrite-stack-ptr , 重写上游共享内存栈指针
- 增加SPIRV拓展_Z25__spirv_RoundFToTF32INTELf的支持 , 提升tl.dot DPAS的精度.

• 性能调优

- 建立首套Triton-XPU性能Benchmark体系, 覆盖Softmax, GEMM, FA等流行内核 , 支持高性能库 (如 XeTLA, CUTLASS, oneDNN) 参考对标
- 性能优化与提升 , 支持多种Optimization Pass 落地 , 包括Coalesce, AcceletateMatmul, RemoveLayoutConversion, Pipeline / Prefetch, Swizzling等
- 关键内核(如GEMM)性能达到Intel性能库XeTLA的90%+

• BUG修复

- 累计解决编译器后端 35+ High issue, 包括性能回归 , Laylout修改传播缺陷 , 单元测试问题等.

PyTorch 生态优化

• CI/CD 创新

- 针对 PyTorch Inductor CPU Performance 基于 Jenkins 设计 AWS Xeon 实例自动化流水线 , 实现 :
 - 自动收集200+ 模型的性能指标
 - 自动化报告生成与发布

CUDA测开实习生@英伟达半导体科技 (上海) 有限公司

2021.08 - 2021.11

CUDA Orin Simulator实践

• 参与NVIDIA Orin t23x SOC的CUDA安全与代码覆盖测试体系构建

- 基于VDK虚拟测试套件搭建自动化测试平台
- 定位failed/timeout用例
- 实现测试镜像版本自动化追踪

☐ 专业技能

- 编译器 : Triton, LLVM, MLIR, SPIRV
- 异构计算 : oneAPI, OpenCL, CUDA, SYCL, Level Zero, ROCm
- AI框架 : Pytorch, IPEX
- AI基础设施 : Jenkins, GitHub Actions, Docker, Vtune Profiler
- 语言 : C/C++, Python, Bash